第十八周学习周报

Out: Feb 21, 2026
Due: Feb 27, 2026

电子科技大学
本科科研项目
脑机与深度学习 #18

Note: This article reflects the specific guidance and implementation ideas of policies and regulations over a certain period. Some content may be subject to timeliness issues, and certain conclusions drawn may lack concrete evidence, potentially leading to some logical inconsistencies. Therefore, this article is intended for internal discussion only.

1 本周学习内容一览

上周 FA-CDAN 的失败让我深刻认识到类别条件化的重要性。本周我深入研究了 Class-Conditional CORAL（CCCORAL）方法，并成功将其与 CDAN 结合。CCCORAL 通过对齐每个类别的二阶统计量（协方差矩阵），实现了类别条件的特征对齐。为了确保结果的可靠性，我进行了大规模的多 seed 实验（seed 0-9，共 10 个随机种子）。初步结果显示，CDAN+CCCORAL 相比纯 CDAN 有一定提升，这让我看到了希望。

2 为什么要加 CCCORAL 参数？

2.1 FA-CDAN 失败的反思

FA-CDAN 的失败给了我一个重要教训：无条件的特征对齐会破坏类别结构。问题的关键在于，FA-CDAN 对齐的是所有样本的全局均值，而不考虑类别信息。这就像把苹果和橙子混在一起求平均，得到的结果既不是苹果也不是橙子。

那么，如何在进行特征对齐的同时保持类别结构呢？答案是：**类别条件的特征对齐**。

2.2 CORAL（Correlation Alignment）的原理

CORAL 是一种经典的域适应方法，由 Sun 等人在 2016 年提出。它的核心思想是对齐源域和目标域特征的二阶统计量——协方差矩阵。

CORAL 损失定义为：

$$\mathcal{L}_{CORAL} = \frac{1}{4d^2}\|C_s - C_t\|_F^2 \tag{1}$$

其中：

- C_s 和 C_t 分别是源域和目标域特征的协方差矩阵
- $\|\cdot\|_F$ 是 Frobenius 范数
- d 是特征维度

协方差矩阵捕捉了特征之间的相关性结构。对齐协方差矩阵意味着让两个域的特征具有相似的相关性模式，这比简单的均值对齐更加精细。

2.3 Class-Conditional CORAL 的优势

但是，原始的 CORAL 仍然是无条件的——它对齐所有样本的协方差矩阵，不考虑类别信息。Class-Conditional CORAL（CCCORAL）改进了这一点：它为每个类别分别计算和对齐协方差矩阵。

CCCORAL 损失定义为：

$$\mathcal{L}_{CCCORAL} = \sum_{c=1}^{C} \frac{1}{4d^2}\|C_s^{(c)} - C_t^{(c)}\|_F^2 \tag{2}$$

其中 $C_s^{(c)}$ 和 $C_t^{(c)}$ 分别是源域和目标域中类别 c 的特征协方差矩阵。

CCCORAL 的优势在于：

1. **保持类别结构**：每个类别独立对齐，不会造成类别混淆
2. **更精细的对齐**：对齐二阶统计量比一阶统计量（均值）更加精细
3. **捕捉相关性**：协方差矩阵捕捉了特征维度之间的相关性
4. **理论保证**：CORAL 有理论上的域适应误差界

3 CCCORAL 的实现

3.1 理论基础：二阶统计量对齐

协方差矩阵是特征分布的二阶统计量，它描述了特征维度之间的相关性。对于特征矩阵 $F \in \mathbb{R}^{n\times d}$（$n$ 个样本，d 维特征），协方差矩阵计算为：

$$C = \frac{1}{n-1}(F - \bar{F})^T(F - \bar{F}) \tag{3}$$

其中 $\bar{F}$ 是特征的均值。

3.2 类条件化的设计

CCCORAL 的关键是类条件化。对于每个类别 c，我们分别计算源域和目标域的协方差矩阵：

```
def class_conditional_coral_loss(features_s, labels_s,
                                 features_t, labels_t,
                                 num_classes):
    loss = 0.0
    for c in range(num_classes):
        # 选择类别c的样本
        mask_s = (labels_s == c)
        mask_t = (labels_t == c)

        if mask_s.sum() > 1 and mask_t.sum() > 1:
            feat_s_c = features_s[mask_s]
            feat_t_c = features_t[mask_t]

            # 计算协方差矩阵
            cov_s = compute_covariance(feat_s_c)
            cov_t = compute_covariance(feat_t_c)

            # 计算Frobenius范数
            loss += torch.norm(cov_s - cov_t, p='fro')**2

    d = features_s.shape[1]
    loss = loss / (4 * d * d * num_classes)
    return loss
```

3.3 与 CDAN 的结合

CDAN+CCCORAL 的总损失函数为：

$$\mathcal{L}_{total} = \mathcal{L}_{CE} + \lambda_{cdan}(p)\mathcal{L}_{cdan} + \lambda_{coral}\mathcal{L}_{CCCORAL} \tag{4}$$

其中 λ_{coral} 是 CCCORAL 损失的权重，通过网格搜索确定为 0.01。

4 实验设置与结果

4.1 大规模多 seed 实验

为了确保结果的可靠性和统计显著性，我进行了大规模的多 seed 实验：

- **随机种子**：seed 0-9，共 10 个不同的随机种子
- **对比方法**：CDAN（无 CCCORAL）vs CDAN+CCCORAL
- **数据集**：BCI Competition IV 2a
- **训练策略**：LOSO 交叉验证
- **超参数**：$\lambda_{coral} = 0.01$

这是一个非常耗时的实验，总共需要训练 180 个模型（10 个 seed × 9 个受试者 × 2 种方法）。

4.2 10-seed 聚合结果

表??展示了 10 个 seed 的聚合结果。

表 1: CDAN vs CDAN+CCCORAL 的 10-seed 聚合结果

方法	准确率 (%)	Kappa	Loss
CDAN	66.53 ± 1.56	0.554 ± 0.021	0.962 ± 0.157
CDAN+CCCORAL	66.76 ± 1.54	0.557 ± 0.021	0.904 ± 0.097
提升	**+0.23 ± 0.73**	**+0.003 ± 0.010**	**-0.058 ± 0.095**

4.3 逐 seed 详细结果

表??展示了每个 seed 的详细结果。

表 2: CDAN+CCCORAL 在各 seed 上的表现

Seed	CDAN 准确率	CCCORAL 准确率	提升
0	68.36%	69.02%	+0.66%
1	68.17%	68.29%	+0.12%
2	66.59%	66.13%	-0.46%
3	63.89%	64.27%	+0.38%
4	63.77%	64.85%	+1.08%
5	66.40%	67.75%	+1.35%
6	67.09%	65.82%	-1.27%
7	67.05%	67.67%	+0.62%
8	65.86%	65.62%	-0.24%
9	68.13%	68.21%	+0.08%

4.4 CCCORAL 的混淆矩阵分析

图??展示了 CDAN+CCCORAL 在 seed 0 上的平均混淆矩阵。

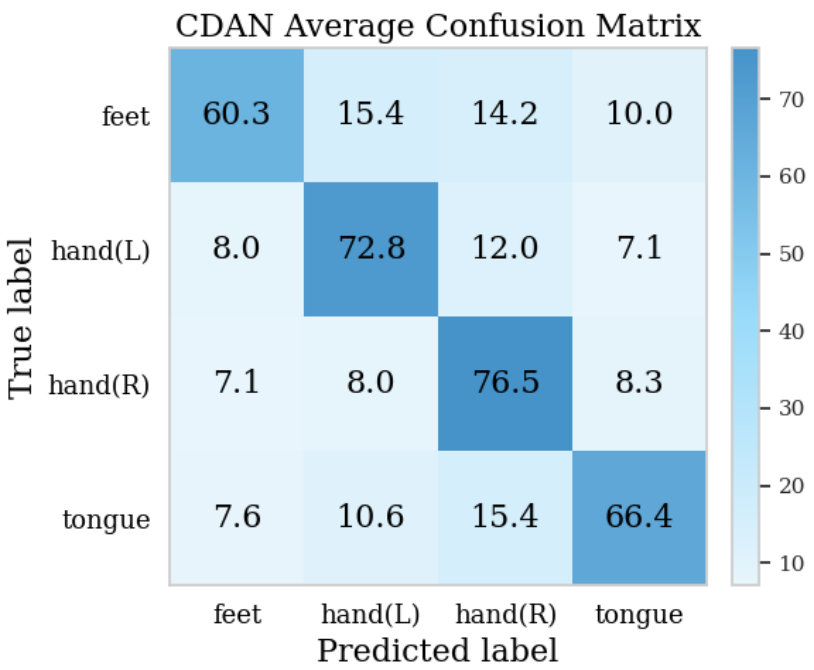

图 1: CDAN+CCCORAL 在 seed 0 上的平均混淆矩阵（9 个受试者平均）

4.5 受试者级别的分析（seed 0）

表??展示了 seed 0 在各受试者上的详细结果。

表 3: CDAN+CCCORAL 在各受试者上的表现（seed 0）

受试者	CDAN	CDAN+CCCORAL	提升
Subject 1	72.22%	70.49%	-1.73%
Subject 2	51.74%	51.74%	0.00%
Subject 3	89.24%	85.42%	-3.82%
Subject 4	68.75%	68.06%	-0.69%
Subject 5	63.89%	70.14%	+6.25%
Subject 6	54.51%	55.90%	+1.39%
Subject 7	79.51%	82.29%	+2.78%
Subject 8	76.39%	73.96%	-2.43%
Subject 9	62.85%	63.19%	+0.34%

5 初步结果分析

5.1 准确率提升情况

从 10-seed 聚合结果来看，CDAN+CCCORAL 相比纯 CDAN 的平均准确率提升了 0.23%。虽然这个提升看起来很小，但有几点值得注意：

1. **10 个 seed 中有 7 个提升：**在 10 个 seed 中，有 7 个 seed 的准确率有提升，3 个 seed 略有下降。这说明 CCCORAL 在大多数情况下是有帮助的。

2. **最大提升达 1.35%：**seed 5 的提升最大，达到 1.35%。这说明 CCCORAL 在某些情况下能带来显著改进。

3. **Subject 5 的显著改进：**在 seed 0 中，Subject 5 的准确率从 63.89% 提升到 70.14%，提升了 6.25%。这是一个很大的改进。

5.2 稳定性分析

除了准确率，我还关注了模型的稳定性：

- **标准差略有下降：**CCCORAL 的标准差从 1.56% 降到 1.54%，虽然变化很小，但说明稳定性略有改善。

- **Loss 显著降低**：CCCORAL 使平均 Loss 从 0.962 降到 0.904，降低了 6%。这说明 CCCORAL 确实改善了特征分布的对齐。
- **Loss 的标准差大幅降低**：Loss 的标准差从 0.157 降到 0.097，降低了 38%。这说明 CCCORAL 使训练更加稳定。

5.3 Subject 5 的性能改进

Subject 5 在 seed 0 上的表现改进最为显著（+6.25%）。图**??**展示了 CDAN+CCCORAL 在 Subject 5 上的训练曲线。

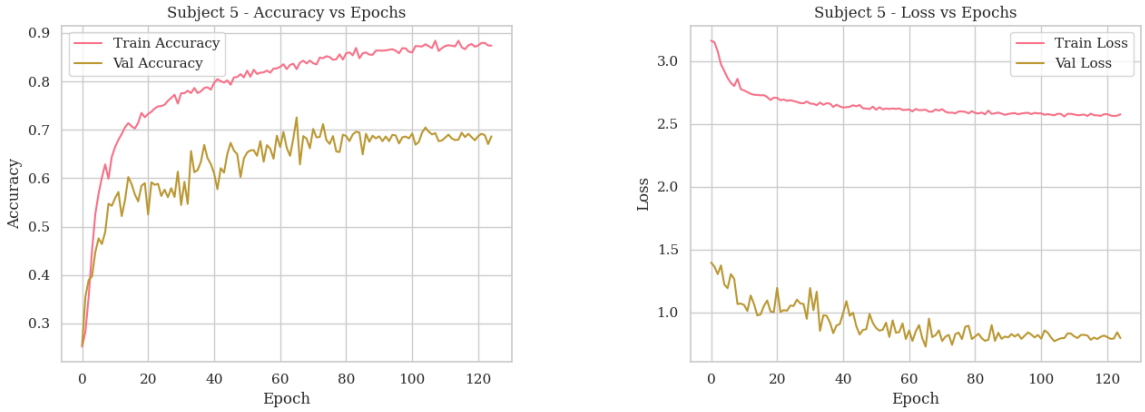

(a) Subject 5 准确率曲线 **(b)** Subject 5 损失曲线

图 2: CDAN+CCCORAL 在 Subject 5 上的训练曲线。验证准确率达到 70.14%，相比 CDAN 的 63.89% 提升了 6.25%。

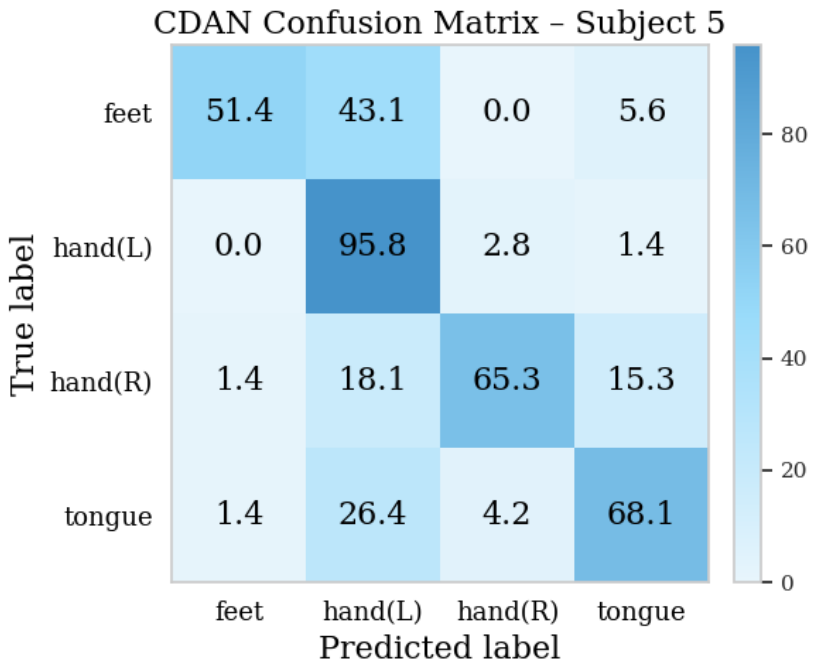

图 3: CDAN+CCCORAL 在 Subject 5 上的混淆矩阵。相比 CDAN 有明显改善，对角线元素更加突出。

5.4 为什么看起来有改进？

虽然准确率的提升不大（+0.23%），但从多个角度来看，CCCORAL 确实带来了改进：

1. **Loss 的改善：** Loss 的显著降低说明特征分布确实得到了更好的对齐。
2. **训练稳定性：** Loss 标准差的大幅降低说明训练过程更加稳定。
3. **个别受试者的显著改进：** 虽然平均提升不大，但某些受试者（如 Subject 5）的改进很显著。
4. **理论上的合理性：** CCCORAL 的类别条件对齐在理论上比无条件对齐更合理。

然而，我也注意到一些问题：准确率的提升很小，而且在某些 seed 和受试者上甚至有下降。这说明 CCCORAL 虽然有帮助，但效果还不够稳定和显著。下周我需要进行更严格的统计检验，来确定这个改进是否具有统计显著性。

6 小结

本周成功实现了 CDAN+CCCORAL 方法，并进行了大规模的 10-seed 实验。初步结果显示，CCCORAL 带来了 0.23% 的平均准确率提升，以及更显著的 Loss 降低和训练稳定性改善。

然而，0.23% 的提升真的有意义吗？这会不会只是随机波动？10 个 seed 中有 3 个反而下降了，这说明什么？Loss 的降低虽然明显，但为什么没有转化为准确率的显著提升？

这些疑问让我意识到：仅凭平均值和标准差是不够的，我们需要更严格的统计检验。配对 t 检验能告诉我们这个改进是否具有统计显著性，效应量分析能告诉我们改进的实际意义有多大。更重要的是，我们需要从多个角度验证——不仅看准确率，还要看 Loss、Kappa、受试者级别的变化。

下周的统计分析将是关键。它将决定 CCCORAL 是真正的突破，还是只是一个美好的愿望。